

Cuánto gasta energy-bot

QUÉ CONSUME

El bot le habla al modelo en tres momentos. Nada más gasta: los saludos, los botones Sí/No, guardar en Postgres y el comando **reiniciar** no cuestan nada porque no salen de tu máquina.

Leer el recibo

0,0018

USD

Una vez por conversación, cuando el usuario manda la foto. Es la llamada con imagen: la foto sola son unos 1.000 tokens, dos tercios del costo del renglón.

Generar el plan

0,0031

USD

Una vez por conversación, al terminar las preguntas. Es la más cara porque reenvía la foto del recibo y además escribe texto largo.

Responder una pregunta libre

0,0013

USD

Cada vez que el usuario escribe algo fuera de guion, en cualquier paso. Sin imagen y con respuesta corta, es la más barata. Es la única que se repite sin límite.

TOTAL POR CONVERSACIÓN COMPLETA

Recibo + plan, sin preguntas de por medio

USD 0,0050

MEDICIÓN REAL

No son estimaciones: son las llamadas que corrieron en las pruebas de hoy, léidas del log **[ai]** que imprime la consola.

LLAMADA	TOKENS ENTRADA	TOKENS SALIDA	COSTO USD
Leer el recibo	1.436	77	0,00182
Generar el plan	1.461	335	0,00314
Pregunta sobre su plan	762	111	0,00132
Pregunta fuera de tema	740	83	0,00115
Pregunta durante el flujo	761	141	0,00147


CUÁNTAS PETICIONES ENTRAN EN USD 5

Tres escenarios, según cuánto pregunte la gente. El del medio es el realista.

1.000 conversaciones al hilo Recibo + plan, sin preguntas	560 conversaciones con preguntas Recibo + plan + 3 preguntas	3.800 preguntas sueltas Si sólo se conversa, sin recibo
---	--	---

Así se reparte el gasto de una conversación con tres preguntas — **USD**

0,0089 en total:



LA PREGUNTA LIBRE, EN DETALLE

USD 0,0013 cada una — entre 0,0012 y 0,0015 según lo que conteste. Unos 750 tokens de entrada y 100 de salida. Con los USD 5 de crédito son **unas 3.800 preguntas**: para que se te acabe el saldo sólo con esto, alguien tendría que escribirte más de diez mensajes por día durante un año.

Los 750 tokens de entrada no dependen de lo que pregunte: son casi todos el contexto que le mandamos en cada mensaje — las reglas de qué puede y qué no puede responder, más el recibo, los electrodomésticos y el plan de ese

usuario. Eso es lo que hace que conteste con *sus* números y no con generalidades.

Sale barata porque no lleva imagen y responde en dos o tres frases. Rechazar una pregunta fuera de tema cuesta lo mismo que contestar una buena: el modelo igual tiene que leer todo para decidir.

PARA GASTAR MENOS

No reenviar la foto al generar el plan. Hoy el plan manda otra vez la imagen del recibo por si el modelo necesita volver a mirarla, y eso son ~1.000 tokens que ya extrajimos. Sacarlo baja el plan de 0,0031 a unos 0,0011: la conversación pasa de 0,0050 a **0,0030**, un 40% menos. Es una línea de código; el costo es que el plan se arma sólo con los datos extraídos.

La heurística de preguntas ya te está ahorrando. Durante las preguntas de electrodomésticos, decidir si el usuario respondió o preguntó se hace con una regla local, no con el modelo. Si esa clasificación la hiciera la IA serían 6 llamadas más por conversación: **+0,0078**, más del doble de lo que sale hoy.

No hay tope por usuario. Cada mensaje fuera de guion es una llamada, y nada impide que una sola persona mande cien. Cien mensajes son USD 0,13 — poco, salvo que alguien lo haga a propósito. Si el bot va a estar abierto al público, conviene un límite diario de preguntas por número antes de publicarlo.

Subir de modelo multiplica todo. Con `claude-sonnet-5` la conversación pasa a 0,0096 y con `claude-opus-5` a 0,024 — 2x y 5x. Se cambia con `AI_MODEL` en el `.env`, así que probalo sólo si Haiku falla leyendo recibos reales.

CÓMO VERLO EN VIVO

Cada llamada se imprime en la consola donde corre `pnpm sim` o `pnpm dev`, con el acumulado desde que arrancó el proceso:

```
[ai] claude-haiku-4-5 · 1436 tokens in / 77 out · ~USD 0.00182 · acumulado USD 0.00182
[ai] claude-haiku-4-5 · 1461 tokens in / 335 out · ~USD 0.00314 · acumulado USD 0.00496
```

El saldo real y la facturación oficial están en [console.anthropic.com → Usage](https://console.anthropic.com/usage).

El acumulado del log se reinicia cada vez que reiniciás el proceso.

Medido el 3 de septiembre de 2026 · tarifas de claude-haiku-4-5 vigentes a esa fecha